



PROJET

RCP217- IA pour des données multimédia

RECOMMANDATION SOCIALE

PLUSQUELLEC Valérie
Septembre 2026

TABLE DES MATIERES

INTRODUCTION	1
I. ANALYSES EXPLORATOIRES DES DONNÉES.....	2
A. PRÉPARATION DES DONNÉES	2
1. Préparation des évaluations	2
2. Préparation du réseau de confiance entre utilisateurs.....	2
B. ANALYSE DES ÉVALUATIONS	3
C. ACTIVITÉ DES UTILISATEURS ET DES ITEMS	3
1. Activité des utilisateurs.....	3
2. Activité des items	4
3. Sparsité de la matrice utilisateurs-items	5
D. ANALYSE DU RÉSEAU DE CONFIANCE	5
E. CONSÉQUENCES POUR LA MODÉLISATION	5
II. PROTOCOLE EXPÉRIMENTAL	7
A. DÉFINITION DES SCÉNARIOS WARM-START ET COLD-START	7
B. CONSTRUCTION DES ENSEMBLES D'APPRENTISSAGE, DE VALIDATION ET DE TEST	7
C. INDÉPENDANCE DES JEUX DE VALIDATION ET DE TEST	8
D. MÉTRIQUE D'ÉVALUATION : MAE	9
E. STRATÉGIE DE SÉLECTION DES HYPERPARAMÈTRES	9
III. MODÈLES DE RÉFÉRENCE NON SOCIAUX	10
A. MODÈLE DE MOYENNE GLOBALE	10
B. MODÈLE AVEC BIAIS UTILISATEURS ET ITEMS	10
C. MODÈLE À FACTORISATION MATRICIELLE (MF).....	11
D. SÉLECTION ET COMPARAISON DES MODELES	11

IV. EXTENSION SOCIALE DE LA FACTORISATION MATRICIELLE	13
A. PRINCIPE DE L'EXTENSION SOCIALE	13
B. MODÈLE DE FACTORISATION MATRICIELLE SOCIALE.....	13
C. SÉLECTION DES CONFIGURATIONS SOCIALES.....	14
V. RÉSULTATS FINAUX	15
A. COMPARAISON DES MODÈLES	15
B. APPORT DU RÉSEAU DE CONFIANCE	16
C. DISCUSSION ET LIMITES	16
CONCLUSION	18

INTRODUCTION

Les systèmes de recommandation ont pour objectif de proposer à un utilisateur des contenus ou des produits susceptibles de l'intéresser. Les méthodes de filtrage collaboratif exploitent les évaluations attribuées par les utilisateurs. Leur efficacité dépend cependant des évaluations disponibles, alors qu'un utilisateur ne note généralement qu'une petite partie des produits proposés.

Le jeu de données Epinions, étudié dans ce projet, contient à la fois des évaluations de produits (appelés items) et des informations sur les relations entre utilisateurs. L'article *SoRec : Social Recommendation Using Probabilistic Matrix Factorization* propose d'intégrer ces relations sociales à un modèle de factorisation matricielle. Les résultats présentés dans l'article montrent que SoRec obtient de meilleures performances que les méthodes non sociales avec lesquelles il est comparé.

Ce projet étudie cet apport du contexte social sur les données Epinions à travers la problématique suivante : dans quelle mesure l'intégration du réseau de confiance d'Epinions influence-t-elle les performances d'un modèle de recommandation, en particulier lorsque l'utilisateur ne dispose pas d'un historique d'évaluations ?

Dans un premier temps, les données d'évaluation et le réseau de confiance sont analysés pour en étudier la structure. Un protocole expérimental distinguant les situations de warm-start et de cold-start utilisateur est ensuite construit. Des modèles de référence sont développés, dont une factorisation matricielle utilisant uniquement les évaluations. Cette factorisation est par la suite étendue afin d'intégrer l'information issue du réseau de confiance, en s'inspirant du principe proposé dans SoRec. Enfin, les approches sociales et non sociales sont comparées selon que l'utilisateur dispose ou non d'un historique d'évaluations.

I. ANALYSES EXPLORATOIRES DES DONNÉES

A. PRÉPARATION DES DONNÉES

1. Préparation des évaluations

Dans le jeu de données Epinions, les évaluations sont réparties dans des fichiers individuels, chaque fichier correspondant à un utilisateur. L'identifiant de l'utilisateur est donc extrait du nom du fichier. Pour chaque évaluation, les autres informations retenues sont l'item évalué, la note attribuée et la date de l'évaluation.

Un contrôle de la qualité des données a été effectué. Les observations sans identifiant d'item et les doublons exacts ont été supprimés. Lorsqu'un couple utilisateur-item comportait plusieurs évaluations, seule la plus récente a été conservée.

Après nettoyage, le jeu de données utilisé pour la suite de l'étude présente les caractéristiques suivantes :

Caractéristique	Valeur
Nombre d'évaluations exploitables	1 238 946
Nombre d'utilisateurs	128 962
Nombre d'items	346 658
Échelle des notes	1–5

TABLE I.1 – Tableau récapitulatif des évaluations.

2. Préparation du réseau de confiance entre utilisateurs

Le réseau de confiance est constitué de relations orientées entre utilisateurs : un utilisateur source déclare faire confiance à un utilisateur cible. Les relations comportant un identifiant manquant, les doublons et les relations d'un utilisateur vers lui-même ont été supprimés.

Après nettoyage, le réseau contient 580 526 relations de confiance. Leur mise en correspondance avec les données d'évaluation est étudiée dans la suite de l'analyse exploratoire.

B. ANALYSE DES ÉVALUATIONS

La répartition des notes attribuées par les utilisateurs est présentée dans la figure I.2. Les notes élevées sont largement majoritaires : les notes de 4 et 5 représentent respectivement 29,78 % et 43,35 % des évaluations. À l'inverse, les notes de 1 et 2 représentent chacune moins de 8 % des observations. La note moyenne est de 3,94 et la note médiane de 4.




FIGURE I.2 – Distribution des notes attribuées par les utilisateurs.

Cette distribution révèle une tendance générale vers les notes élevées. Elle justifie la comparaison avec des modèles de référence simples, fondés sur la moyenne globale puis sur les biais propres aux utilisateurs et aux items, pour déterminer si les approches plus complexes apportent une amélioration par rapport à ces modèles de référence.

C. ACTIVITÉ DES UTILISATEURS ET DES ITEMS

1. Activité des utilisateurs

Le nombre d'évaluations par utilisateur est très inégalement réparti (voir figure I.3). La médiane est de seulement 2 évaluations par utilisateur, alors que la moyenne est d'environ 9,6. Cette différence s'explique par la présence d'un petit nombre d'utilisateurs très actifs. Par ailleurs, 71,4 % des utilisateurs ont évalué entre 1 et 5 items, et 83,1 % en ont évalué au plus 10. La majorité des utilisateurs dispose donc d'un historique d'évaluations très limité.




FIGURE I.3 – Répartition des utilisateurs selon leur nombre d'évaluations.

2. Activité des items

La répartition est de nouveau très déséquilibrée du côté des items (**voir figure I.4**) : 89,68 % des items ont reçu au plus 5 évaluations, tandis qu'un nombre beaucoup plus faible d'items concentre un grand nombre d'évaluations.




FIGURE I.4 – Répartition des items selon leur nombre d'évaluations.

3. Sparsité de la matrice utilisateurs-items

La faible activité de la majorité des utilisateurs, associée au faible nombre d'évaluations reçues par une grande partie des items, conduit à une matrice utilisateurs-items très creuse. Avec 128 962 utilisateurs et 346 658 items, près de 44,7 milliards de couples sont théoriquement possibles, alors que seulement 1 238 946 évaluations sont observées. La densité de la matrice est d'environ 0,00277 % : l'immense majorité des couples utilisateur-item ne possède aucune évaluation.

Cette sparsité limite les informations disponibles pour apprendre les préférences des utilisateurs et les caractéristiques des items à partir des seules évaluations. Cette limitation est d'autant plus importante pour les utilisateurs disposant de très peu d'historique. L'information issue du réseau de confiance pourrait alors constituer une source complémentaire pour le système de recommandation.

D. ANALYSE DU RÉSEAU DE CONFIANCE

Le réseau de confiance doit pouvoir être mis en relation avec les données d'évaluation pour être utilisé par les modèles de recommandation. Après nettoyage, il contient 580 526 relations. Parmi celles-ci, 509 872, soit 87,83 %, relient deux utilisateurs disposant d'évaluations.

Ces relations concernent 63 559 utilisateurs, soit 49,29 % des utilisateurs présents dans les données d'évaluation. Ainsi, même si l'information sociale n'est pas disponible pour l'ensemble des utilisateurs, elle concerne près de la moitié d'entre eux et la grande majorité des relations du réseau peut être associée aux données d'évaluation.

Ces résultats montrent que le réseau de confiance fournit une quantité suffisante d'informations pour étudier son apport dans un modèle de recommandation.

E. CONSÉQUENCES POUR LA MODÉLISATION

L'analyse exploratoire met en évidence plusieurs caractéristiques qui orientent les choix de modélisation et la construction du protocole expérimental.

Tout d'abord, la distribution des notes est fortement concentrée vers les valeurs élevées. Une partie des évaluations peut donc potentiellement être expliquée par des tendances générales de notation, liées à la moyenne des notes mais aussi aux comportements propres aux utilisateurs et aux items. Des modèles simples fondés sur la moyenne globale puis sur les biais utilisateur et item seront utilisés comme références pour déterminer si des modèles plus complexes apportent une amélioration.

La matrice utilisateurs-items est par ailleurs extrêmement creuse, avec une densité de seulement 0,00277 %. Une factorisation matricielle sera utilisée pour représenter les utilisateurs et les items dans un espace latent à partir des évaluations observées.

L'activité des utilisateurs constitue un autre élément important : 71,4 % d'entre eux disposent de cinq évaluations ou moins. Cette faible quantité d'information conduit à s'intéresser plus

particulièrement au cas où l'historique d'un utilisateur est totalement absent. Un scénario de cold-start utilisateur sera donc construit pour évaluer les modèles dans cette situation, en complément d'un scénario warm-start où les utilisateurs disposent d'évaluations dans le jeu d'apprentissage.

Enfin, l'analyse du réseau de confiance montre que 87,83 % des relations relient deux utilisateurs disposant d'évaluations et que ces relations concernent près de la moitié des utilisateurs du jeu de données. Cette information peut donc être mise en relation avec les évaluations et intégrée à la modélisation. Elle permettra d'étudier si le réseau de confiance constitue une source d'information utile lorsque l'historique d'évaluation d'un utilisateur est absent.

II. PROTOCOLE EXPÉRIMENTAL

A. DÉFINITION DES SCÉNARIOS WARM-START ET COLD-START

Les expériences présentées dans l'article SoRec montrent que l'intégration de l'information sociale améliore les performances de la factorisation matricielle lorsque la quantité d'évaluations disponible pour l'apprentissage diminue. Plutôt que de reproduire ce protocole en faisant varier globalement la proportion d'évaluations disponibles, cette étude se concentre sur un cas particulier : le cold-start utilisateur.

Le protocole place ainsi certains utilisateurs dans une situation où ils ne disposent d'aucun historique d'évaluation dans le jeu d'apprentissage, tout en conservant des relations exploitables dans le réseau de confiance. L'objectif est de déterminer si cette information sociale permet d'améliorer leurs prédictions par rapport à une approche reposant uniquement sur les évaluations.

Dans le scénario warm-start, les utilisateurs du jeu d'évaluation sont déjà connus du modèle : ils disposent d'au moins une évaluation dans le jeu d'apprentissage. Le modèle peut donc s'appuyer sur leur historique pour apprendre leur représentation.

Dans le scénario cold-start, les utilisateurs du jeu d'évaluation ne disposent d'aucune évaluation dans le jeu d'apprentissage. Ils sont en revanche présents dans le réseau de confiance, ce qui permet d'étudier si les relations de confiance peuvent contribuer à leur représentation en l'absence d'historique.

Ces deux scénarios permettent de comparer les modèles selon que l'utilisateur dispose ou non d'un historique d'évaluation dans les données d'apprentissage, et d'étudier dans quelle mesure l'apport du réseau de confiance dépend de cette situation.

B. CONSTRUCTION DES ENSEMBLES D'APPRENTISSAGE, DE VALIDATION ET DE TEST

Un même jeu d'apprentissage est utilisé pour les deux scénarios. Des jeux de validation et de test distincts sont en revanche construits pour évaluer les modèles dans les scénarios warm-start et cold-start.

Pour construire les ensembles cold-start, des utilisateurs ne possédant qu'une seule évaluation sont sélectionnés. Trois conditions sont retenues :

- l'utilisateur sélectionné ne doit posséder qu'une seule évaluation ; celle-ci est réservée à la validation ou au test, et n'est donc pas présente dans le jeu d'apprentissage ;
- l'utilisateur sélectionné doit disposer de relations de confiance exploitables, pour que le modèle social puisse utiliser cette information malgré l'absence d'historique d'évaluation ;

- l’item correspondant à l’unique évaluation de l’utilisateur sélectionné doit avoir été évalué par au moins un autre utilisateur, pour qu’il reste présent dans le jeu d’apprentissage.

Au total, 8 562 utilisateurs répondent à ces critères. Parmi eux, 2 000 sont sélectionnés pour la validation cold-start et 2 000 pour le test cold-start, par échantillonnage stratifié selon la note. Pour chacun de ces 4 000 utilisateurs, l’unique évaluation est réservée à l’ensemble correspondant : elle n’est pas utilisée pour l’apprentissage et constitue la note à prédire par le modèle. Les 4 562 utilisateurs éligibles non sélectionnés ne sont pas placés en situation de cold-start : leur évaluation reste dans les données disponibles pour la suite du découpage.

Une fois les 4 000 évaluations cold-start mises de côté, les évaluations restantes sont réparties entre le jeu d’apprentissage et les ensembles de validation et de test warm-start. Pour les ensembles de validation et de test warm-start, chaque utilisateur et chaque item doivent déjà apparaître dans le jeu d’apprentissage. Le modèle dispose ainsi déjà d’informations sur l’utilisateur et l’item avant de prédire l’évaluation de validation ou de test. Lorsqu’une observation de validation ou de test ne respecte pas cette condition, elle est réintégrée dans le jeu d’apprentissage.

Le découpage final obtenu est présenté dans le tableau II.1.

Ensemble	Nombre d’évaluations
Apprentissage	1 046 190
Validation warm-start	94 313
Test warm-start	94 443
Validation cold-start	2 000
Test cold-start	2 000

TABLE II.1 – Résumé du découpage final.

C. INDÉPENDANCE DES JEUX DE VALIDATION ET DE TEST

Dans le but de préserver l’indépendance de l’évaluation finale, les ensembles de validation et de test ont des rôles distincts. Les ensembles de validation sont utilisés pour comparer les configurations des modèles et sélectionner leurs hyperparamètres. Les ensembles de test ne sont utilisés qu’après cette sélection, pour évaluer les modèles retenus.

Cette séparation est appliquée aux deux scénarios : les choix effectués pour le warm-start reposent sur la validation warm-start, tandis que ceux destinés au cold-start reposent sur la validation cold-start. Les performances finales sont ensuite mesurées sur les ensembles de test correspondants, qui n’interviennent pas dans la sélection des modèles.

D. MÉTRIQUE D'ÉVALUATION : MAE

La MAE (erreur absolue moyenne) est retenue comme métrique d'évaluation. Elle est également utilisée dans l'article SoRec. Elle est définie par :

$$MAE = \frac{1}{N} \sum_{(u,i) \in T} |r_{ui} - \hat{r}_{ui}|$$

où r_{ui} désigne la note attribuée par l'utilisateur u à l'item i , $\hat{r}_{ui}$ la note prédite par le modèle et N le nombre d'évaluations considérées.

La MAE mesure donc l'écart absolu moyen entre les notes observées et les notes prédites, sur l'échelle de notation de 1 à 5. Une valeur faible indique une meilleure précision des prédictions.

D'autres métriques, comme la RMSE, auraient également pu être utilisées. La MAE a été retenue pour son interprétation directe et pour permettre la comparaison avec les résultats présentés dans l'article SoRec.

Cette métrique est utilisée pour la sélection des modèles sur les ensembles de validation et pour leur comparaison finale sur les ensembles de test.

E. STRATÉGIE DE SÉLECTION DES HYPERPARAMÈTRES

Les hyperparamètres des modèles sont sélectionnés sur les ensembles de validation en utilisant la MAE comme critère de comparaison.

Compte tenu du nombre de paramètres à ajuster et du coût d'apprentissage des modèles de factorisation, une recherche exhaustive de toutes les combinaisons n'a pas été réalisée. Une recherche séquentielle a été privilégiée : les principaux hyperparamètres sont étudiés successivement, les valeurs retenues à une étape étant conservées pour les suivantes. Cette démarche réduit le nombre de configurations à tester tout en permettant d'étudier l'influence des principaux hyperparamètres.

Pour les modèles entraînés de manière itérative, un arrêt anticipé (*early stopping*) est utilisé : l'apprentissage est interrompu lorsque la MAE de validation ne s'améliore plus. Le nombre d'époques est ainsi déterminé à partir de la validation, tout en limitant le surapprentissage et les calculs inutiles.

La sélection des hyperparamètres est effectuée séparément selon les deux scénarios : une configuration est recherchée sur la validation warm-start et une autre sur la validation cold-start.

III. MODÈLES DE RÉFÉRENCE NON SOCIAUX

A. MODÈLE DE MOYENNE GLOBALE

Un premier modèle de référence consiste à prédire chaque évaluation par la moyenne des notes du jeu d'apprentissage :

$$\hat{r}_{ui} = \mu$$

où μ représente la moyenne globale des évaluations d'apprentissage.

Ce modèle ne tient compte ni de l'utilisateur ni de l'item. Il constitue une référence simple permettant de vérifier si les modèles suivants apportent une amélioration par rapport à une prédiction identique pour toutes les observations.

B. MODÈLE AVEC BIAIS UTILISATEURS ET ITEMS

Le modèle de moyenne globale peut être enrichi en prenant en compte les différences de comportement entre utilisateurs et entre items. La prédiction s'écrit :

$$\hat{r}_{ui} = \mu + b_u + b_i$$

où μ est la moyenne globale des évaluations, b_u le biais associé à l'utilisateur u et b_i celui associé à l'item i .

Le biais utilisateur traduit sa tendance à attribuer des notes plus ou moins élevées que la moyenne, tandis que le biais item représente la tendance d'un item à recevoir des notes plus ou moins élevées.

Les biais sont estimés sur le jeu d'apprentissage en minimisant une erreur quadratique régularisée :

$$\sum_{(u,i) \in \mathcal{T}} (r_{ui} - \mu - b_u - b_i)^2 + \lambda \left(\sum_u b_u^2 + \sum_i b_i^2 \right)$$

La régularisation pénalise les biais de grande amplitude, notamment lorsque l'utilisateur ou l'item dispose de peu d'évaluations. Le paramètre λ , qui contrôle l'intensité de la régularisation, est sélectionné sur les ensembles de validation en minimisant la MAE.

C. MODÈLE À FACTORISATION MATRICIELLE (MF)

La factorisation matricielle cherche à représenter chaque utilisateur et chaque item par un vecteur de k facteurs latents. Ces facteurs sont appris à partir des évaluations observées et permettent de représenter les préférences des utilisateurs et les caractéristiques des items dans un même espace latent.

Le modèle utilisé complète les biais précédents par l'interaction entre les facteurs latents de l'utilisateur et de l'item :

$$\hat{r}_{ui} = \mu + b_u + b_i + x_u^T y_i$$

où x_u et y_i sont respectivement les vecteurs de facteurs latents de l'utilisateur u et de l'item i . Leur produit scalaire $x_u^T y_i$ permet de modéliser des interactions qui ne sont pas prises en compte par les seuls biais.

Les paramètres sont estimés en minimisant une erreur quadratique régularisée :

$$\mathcal{L} = \sum_{(u,i) \in \mathcal{T}} (r_{ui} - \mu - b_u - b_i - x_u^T y_i)^2 + \lambda \left(\sum_u b_u^2 + \sum_i b_i^2 + \sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Le premier terme mesure l'écart entre les notes observées et prédites. Le terme de régularisation pénalise les biais et les facteurs latents de grande amplitude pour limiter le surapprentissage. Le paramètre λ contrôle l'intensité de cette régularisation.

Les paramètres sont appris par descente de gradient stochastique. Le nombre de facteurs latents k , le taux d'apprentissage et le paramètre de régularisation λ sont sélectionnés sur les ensembles de validation selon la stratégie décrite précédemment.

Dans le scénario cold-start, le biais et les facteurs latents de l'utilisateur ne peuvent pas être appris à partir de ses évaluations, puisqu'aucune n'est présente dans le jeu d'apprentissage. Ces termes sont donc nuls et la prédiction repose sur la moyenne globale et le biais de l'item :

$$\hat{r}_{ui} = \mu + b_i$$

D. SELECTION ET COMPARAISON DES MODELES

Les performances des modèles non sociaux sont évaluées sur les ensembles de validation warm-start et cold-start. La moyenne globale ne comporte aucun hyperparamètre et constitue le modèle de référence le plus simple.

Pour le modèle avec biais, le paramètre de régularisation est sélectionné séparément sur les validations warm-start et cold-start. La valeur $\lambda=1$ est retenue dans les deux scénarios, où elle obtient la MAE la plus faible.

Pour la factorisation matricielle, une recherche séquentielle des hyperparamètres a d'abord été réalisée sur la validation warm-start. La configuration retenue utilise 5 facteurs latents, une régularisation de 0,05 et un taux d'apprentissage η de 0,01. Elle obtient une MAE de 0,8100 sur la validation warm-start et de 1,0343 sur la validation cold-start.

Une seconde recherche a été réalisée en utilisant cette fois la MAE cold-start comme critère de sélection. La même démarche séquentielle est appliquée à la dimension latente, au taux d'apprentissage et à la régularisation. Elle conduit à une configuration différente, avec $k=10$, $\eta=0,01$ et $\lambda=0,01$. Cette configuration obtient une MAE de 0,8631 sur la validation warm-start et de 1,0271 sur la validation cold-start.

Modèle	Sélection	Hyperparamètres	MAE val.warm	MAE val.cold
Moyenne globale	—	—	0,9553	1,1775
Biais	Warm-start / Cold-start	$\lambda = 1$	0,8086	1,0323
MF	Warm-start	$k = 5$ $\lambda = 0,05$ $\eta = 0,01$	0,8100	1,0343
MF	Cold-start	$k = 10$ $\lambda = 0,01$ $\eta = 0,01$	0,8631	1,0271

TABLE III.1 – Configurations retenues pour les modèles non sociaux.

En warm-start, le modèle avec biais obtient la meilleure MAE de validation avec 0,8086, légèrement devant la factorisation matricielle. L'ajout de facteurs latents n'apporte donc pas d'amélioration notable dans ce scénario.

En cold-start, la configuration MF sélectionnée pour ce scénario obtient la meilleure MAE avec 1,0271. Ses performances se dégradent toutefois en warm-start. Les configurations privilégiées diffèrent donc selon le scénario considéré et les deux configurations de factorisation matricielle sont conservées pour l'évaluation finale.

IV. EXTENSION SOCIALE DE LA FACTORISATION MATRICIELLE

A. PRINCIPE DE L'EXTENSION SOCIALE

La factorisation matricielle présentée précédemment apprend les représentations latentes des utilisateurs uniquement à partir de leurs évaluations. Cette approche devient cependant limitée lorsque l'historique d'un utilisateur est réduit et, dans le cas du cold-start étudié ici, ne permet pas d'apprendre sa représentation à partir des évaluations puisqu'aucune n'est disponible dans le jeu d'apprentissage.

Le réseau de confiance d'Epinions constitue une source d'information supplémentaire. Dans ce projet, il est intégré à la factorisation matricielle présentée précédemment par l'ajout d'une composante sociale. Dans le scénario cold-start, seules les relations de confiance restent disponibles pour apprendre la représentation de l'utilisateur.

L'objectif est de mesurer si cette information sociale améliore les prédictions lorsque l'historique d'évaluation de l'utilisateur est absent.

B. MODÈLE DE FACTORISATION MATRICIELLE SOCIALE

Le modèle social conserve la formulation de la factorisation matricielle non sociale pour la prédiction des évaluations :

$$\hat{r}_{ui} = \mu + b_u + b_i + U_u^T V_i$$

où μ représente la moyenne globale, b_u et b_i les biais utilisateur et item, et $U_u^T V_i$ l'interaction entre leurs facteurs latents.

Le vecteur latent utilisateur U_u est également utilisé pour modéliser les relations de confiance. À chaque utilisateur cible k du réseau de confiance est associé un vecteur latent Z_k , et la relation sociale est prédite par :

$$\hat{c}_{uk} = g(U_u^T Z_k)$$

où g désigne la fonction sigmoïde :

$$g(x) = \frac{1}{1 + e^{-x}}$$

La composante sociale utilise une pondération inspirée de celle proposée dans SoRec. Pour une relation orientée de l'utilisateur u vers l'utilisateur k , la valeur utilisée est :

$$c_{uk}^* = \sqrt{\frac{d^-(k)}{d^+(u) + d^-(k)}} c_{uk}$$

où $d^+(u)$ représente le degré sortant de l'utilisateur source, $d^-(k)$ le degré entrant de l'utilisateur cible et c_{uk} la relation de confiance observée.

L'apprentissage combine alors l'erreur de prédiction des évaluations et l'erreur de représentation des relations sociales :

$$\mathcal{L} = \frac{1}{2} \sum_{(u,i) \in \mathcal{T}} (r_{ui} - \hat{r}_{ui})^2 + \frac{\lambda_c}{2} \sum_{(u,k) \in \mathcal{C}} (c_{uk}^* - g(U_u^\top Z_k))^2 + \text{régularisation}$$

Le paramètre λ_c contrôle l'importance accordée à la composante sociale. La régularisation est appliquée aux biais et aux différents facteurs latents pour limiter le surapprentissage.

Le partage du vecteur U_u entre les deux composantes constitue le mécanisme central du modèle : les facteurs utilisateurs sont appris conjointement à partir des évaluations et du réseau de confiance. Dans le scénario cold-start, le biais utilisateur reste nul puisqu'aucune évaluation de l'utilisateur n'est disponible dans le jeu d'apprentissage. En revanche, son vecteur latent U_u peut être appris à partir de ses relations sociales et intervenir dans la prédiction de ses évaluations.

C. SÉLECTION DES CONFIGURATIONS SOCIALES

Comme pour la factorisation matricielle non sociale, les hyperparamètres du modèle social sont sélectionnés sur les ensembles de validation. Deux configurations sont recherchées : l'une minimise la MAE en warm-start et l'autre la MAE en cold-start.

La sélection est réalisée séquentiellement pour limiter le coût de calcul. Elle porte sur le poids de la composante sociale λ_c , la dimension de l'espace latent k , le taux d'apprentissage η et le paramètre de régularisation λ . Un arrêt anticipé est utilisé au cours des entraînements.

Configuration	k	λ_c	η	λ	MAE val. warm	MAE val. cold
MF sociale – sélection warm	5	5	0,01	0,05	0,8084	1,0334
MF sociale – sélection cold	10	5	0,02	0,01	0,8369	1,0269

TABLE IV.1 – Configurations retenues pour la factorisation matricielle sociale.

Les deux scénarios conduisent à des configurations différentes. La configuration sélectionnée pour le cold-start obtient une MAE de 1,0269, contre 1,0334 pour celle sélectionnée en warm-start. Cette amélioration s'accompagne d'une dégradation en warm-start. Les deux configurations sont conservées pour l'évaluation finale.

V. RÉSULTATS FINAUX

A. COMPARAISON DES MODÈLES

Après la sélection des hyperparamètres sur les ensembles de validation, les configurations retenues sont évaluées sur les ensembles de test warm-start et cold-start. Ces derniers n'interviennent à aucun moment dans la sélection des modèles et sont uniquement utilisés pour mesurer leurs performances finales.

Modèle	Sélection	MAE test warm	MAE test cold
Moyenne globale	—	0,9542	1,1780
Biais utilisateur + item	Warm / Cold	0,8103	1,0366
MF	Warm-start	0,8132	1,0350
MF	Cold-start	0,8623	1,0254
MF sociale	Warm-start	0,8107	1,0294
MF sociale	Cold-start	0,8361	1,0222

TABLE V.1 – Performances finales sur les ensembles de test.

En warm-start, les modèles avec biais et les configurations de MF sélectionnées pour ce scénario obtiennent des performances très proches. Le modèle avec biais présente la MAE la plus faible avec 0,8103. L'introduction de facteurs latents et de l'information sociale n'apporte donc pas d'amélioration notable dans ce scénario.

La bonne performance du modèle avec biais peut être rapprochée des caractéristiques mises en évidence lors de l'analyse exploratoire. La matrice d'évaluations est extrêmement creuse et une grande partie des utilisateurs et des items ne disposent que de quelques évaluations, ce qui peut limiter l'apprentissage d'interactions latentes spécifiques. Par ailleurs, la distribution des notes est fortement concentrée sur les valeurs élevées. Dans ce contexte, la moyenne globale et les effets propres aux utilisateurs et aux items capturent déjà une part importante de la structure des évaluations, tandis que les facteurs latents apportent peu d'amélioration supplémentaire.

Les configurations sélectionnées pour le cold-start améliorent les performances des deux factorisations matricielles sur cet ensemble, au prix d'une dégradation en warm-start. Le choix des hyperparamètres dépend donc du scénario privilégié.

En cold-start, la moyenne globale et le modèle avec biais obtiennent des MAE supérieures à celles des factorisations sélectionnées pour ce scénario. Parmi les factorisations sélectionnées spécifiquement pour ce scénario, la MF non sociale atteint une MAE de 1,0254 et la MF sociale obtient la meilleure performance avec 1,0222.

B. APPORT DU RÉSEAU DE CONFIANCE

L'apport du réseau de confiance peut être étudié en comparant les factorisations matricielles sociale et non sociale sélectionnées selon le même objectif. En warm-start, la MF sociale obtient une MAE de 0,8107 contre 0,8132 pour la MF non sociale, soit une diminution d'environ 0,3 %. Lorsque les utilisateurs disposent déjà d'un historique d'évaluations, l'information sociale n'apporte donc qu'une amélioration très faible.

En cold-start, la comparaison des deux configurations sélectionnées spécifiquement pour ce scénario conduit à une MAE de 1,0222 pour la MF sociale contre 1,0254 pour la MF non sociale, soit également une diminution d'environ 0,3 %. L'information sociale améliore donc légèrement les prédictions, mais son effet reste très faible.

Cette différence peut être mise en relation avec la nature de l'information disponible pour les utilisateurs cold-start. En l'absence d'évaluations dans le jeu d'apprentissage, la MF non sociale ne peut apprendre ni leur biais utilisateur ni leurs facteurs latents. La prédiction repose alors sur la moyenne globale et le biais associé à l'item. Dans la MF sociale, le biais utilisateur reste également nul, mais le vecteur latent de l'utilisateur peut être appris à partir de ses relations de confiance. Le réseau de confiance permet alors de construire une représentation latente de ces utilisateurs malgré l'absence d'historique d'évaluation.

Cet avantage dans la représentation des utilisateurs ne se traduit cependant que par une faible amélioration de la MAE. Lorsque la MF non sociale est elle aussi sélectionnée spécifiquement pour le cold-start, elle atteint une performance très proche de celle de la MF sociale. L'apport du réseau de confiance reste donc limité dans le cadre expérimental étudié.

C. DISCUSSION ET LIMITES

Les résultats obtenus peuvent être rapprochés de ceux présentés dans l'article SoRec. Sur Epinions, les auteurs comparent notamment SoRec à PMF, une factorisation matricielle ne prenant pas en compte le réseau de confiance. Les résultats obtenus pour une dimension latente égale à 10 sont présentés dans le tableau suivant.

Proportion d'apprentissage	PMF	SoRec	Diminution de la MAE
99 %	0,9885	0,8932	9,6 %
80 %	1,0182	0,9240	9,3 %
50 %	1,0857	0,9751	10,2 %
20 %	1,2276	1,0944	10,9 %

TABLE V.2 – Comparaison des MAE de PMF et SoRec sur Epinions (article SoRec).

SoRec obtient une MAE inférieure à celle de PMF pour toutes les proportions étudiées, avec une diminution d'environ 9 à 11 %. Cet avantage se maintient lorsque la quantité d'évaluations disponibles pour l'apprentissage diminue.

Ces résultats ont motivé le choix de se concentrer ici sur un cas particulier de rareté des données : l'absence complète d'historique pour certains utilisateurs. Les valeurs de MAE ne peuvent toutefois pas être comparées directement. SoRec étudie une diminution globale des évaluations disponibles, tandis que notre protocole isole des utilisateurs sans historique mais disposant de relations de confiance. De plus, le modèle social développé ici s'inspire du principe de SoRec sans en constituer une reproduction exacte. Dans les deux études, l'intégration de l'information sociale améliore la factorisation matricielle non sociale, mais le gain observé ici reste beaucoup plus faible.

Plusieurs limites doivent être prises en compte. Les ensembles warm-start et cold-start diffèrent par leur taille et leur population, ce qui empêche de comparer directement leurs niveaux de MAE pour isoler l'effet du cold-start. L'ensemble cold-test ne contient par ailleurs que 2 000 observations, avec une seule évaluation par utilisateur, contre plus de 94 000 observations pour le warm-test. Enfin, les utilisateurs cold-start disposent tous de relations sociales exploitables : les conclusions ne peuvent donc pas être généralisées aux utilisateurs ne possédant ni historique d'évaluations ni information sociale.

Les résultats reposent également sur une seule partition des données, sans estimation de leur incertitude. Cette limite est particulièrement importante au regard du faible écart observé entre les modèles social et non social. La recherche séquentielle des hyperparamètres ne garantit par ailleurs pas que les configurations retenues soient globalement optimales.

Une extension de l'étude pourrait compléter ce protocole en faisant varier, comme dans SoRec, la proportion d'évaluations utilisée pour l'apprentissage. Il serait alors possible d'étudier conjointement la diminution globale des évaluations disponibles et l'absence complète d'historique pour certains utilisateurs.

CONCLUSION

Cette étude avait pour objectif d'évaluer l'apport de l'information sociale dans un système de recommandation, en particulier lorsque l'utilisateur ne dispose d'aucun historique d'évaluation dans le jeu d'apprentissage. À partir du constat présenté dans l'article SoRec selon lequel l'information sociale peut améliorer la recommandation lorsque les évaluations disponibles se raréfient, le protocole retenu s'est concentré sur ce cas particulier de cold-start utilisateur.

Les résultats montrent qu'en warm-start, l'ajout de facteurs latents et de l'information sociale n'améliore pas les performances par rapport au modèle avec biais. Lorsque les utilisateurs disposent déjà d'un historique d'évaluations, la complexité supplémentaire des modèles de factorisation apporte donc peu de bénéfice.

En cold-start, la factorisation matricielle apporte en revanche une amélioration par rapport au modèle avec biais, avec une diminution de la MAE d'environ 1,1 %. L'intégration du réseau de confiance améliore encore légèrement les prédictions : la factorisation matricielle sociale obtient une MAE de 1,0222, contre 1,0254 pour la factorisation non sociale sélectionnée selon le même objectif, soit une diminution supplémentaire d'environ 0,3 %. Le réseau de confiance apporte donc un complément d'information utile en l'absence d'historique d'évaluation, mais son effet sur les performances reste faible.

Ces conclusions restent liées au cadre expérimental retenu : le scénario cold-start concerne uniquement des utilisateurs disposant de relations sociales exploitables, l'ensemble de test correspondant est de taille limitée et les expériences reposent sur une seule partition des données. La répétition des expériences sur plusieurs partitions permettrait d'évaluer la stabilité du faible avantage observé pour le modèle social.